

基于大模型的运筹优化建模语义纠错方法

答辩人：周泽同

指导教师：李超

2026.4.15



\ 目录 CONTENT

PART 1 毕设工作简介

PART 2 已完成工作




PART 3 存在的问题与后续工作

PART 4 参考文献

毕设工作简介

研究背景


- 优化建模是解决运筹学问题的标准手段。尽管大语言模型在自动优化建模方面展现出**巨大潜力**，其固有的“幻觉”问题会导致**错误**，我们将其分为两类：
 - 语法错误**：生成的代码**无法编译**或求解器认为**不可解**。
 - 语义错误**：生成的代码能够成功运行并输出结果，但其对应的数学模型误解了问题描述中的**核心约束**或**目标**，导致求解结果**与实际需求不符**。




解决语法错误的方法

- 基于工作流的方法：修复智能体触发条件依赖于编译器或求解器返回的**显式报错信息**，即仅发生语法错误时，修复流程才会被激活，因此**无法修复语义错误**。
- 基于监督微调的方法：学习训练数据中的代码范式，倾向于**模仿代码的表面结构**而非理解其背后的数学逻辑，因此难以解读问题描述中的**隐藏约束**。

Chain-of-Experts^[5]: 链式的**专家调用**





LLMOPT^[6]: “**数据、训练、自动化测试**” 框架






解决语义错误的方法

- 回译验证方法的核心洞察：依赖**通用的预训练大模型**作为评估器，只能识别表层的**文本不一致**，而无法有效检测出那些代码可运行但数学本质错误的**隐性语义偏离**。
- 基于层次化搜索的方法：搜索在**扁平的层次**上进行，混杂了**高层的建模决策**与**底层的实现细节**，容易陷入代码层面的**无效微调**，无法有效修正**宏观建模策略**。



研究背景

- 需要一种方法，解决现有研究的以下**痛点**：
 - 具有运筹学领域特定的**错误定位能力** -> 使用垂类数据，微调一个**语义奖励模型**
 - 具有宏微观结合的**错误修正能力** -> 合理划分层次，进行**层次搜索**
 - 具有对于不同难度问题实例合理**分配计算资源**的能力 -> 开发自适应的**门控机制**



研究目标和内容

- 本课题**研究目标**为解决运筹优化建模中LLM易产生**隐性语义错误**的核心问题，构建基于领域特定**语义奖励模型**引导的**分层修复框架**，实现在复杂工业场景下对建模逻辑一致性与求解代码精度的双重提升，同时确保建模的**时间效率**。具体包含以下几个目标：
 - 研究并构建面向运筹学的**语义奖励模型**。
 - 研究并实现基于**蒙特卡洛树搜索**的修正算法。
 - 设计并集成**自适应门控机制**。
- 本课题的**研究内容**主要分为两个部分：
 - 第一部分为构建高精度的**语义奖励模型**，重点在于构造高质量的“正向建模”与“负向语义错误”**样本对**；利用**对比学习**范式对预训练模型进行微调^[10]，使其学习运筹学特定的**对齐特征**。
 - 第二部分为实现**自适应修复系统**，重点在于开发核心推理引擎，实现结合语义奖励分数的**蒙特卡洛树搜索**策略，包括节点扩展、评估与剪枝机制；集成**自适应门控模块**，根据奖励模型的分数动态决定是否启动搜索。


已完成工作

整体框架

- 本课题通过构建**SemOPT**这一框架来解决运筹优化建模中的语义错误。


- 该框架对输入的问题描述处理过程如下：

使用**端到端求解**进行采样 → **语义奖励模型**评估语义一致性 → 根据阈值触发**层次化搜索** → 使用**蒙特卡洛树搜索**进行深度推理。



语义奖励模型

- 数据合成：
 - 轨迹**收集**：从训练集OR-Instruct出发，每个问题通过端到端方法采样N个解，根据目标值与正确解的差值划分**正负样本对**。组合每个问题的样本对形成**偏好数据集**。
 - 轨迹增强：使用**变异算子**对解结构进行扰动，生成更困难的负样本。



Dimension	Operator	Implementation Logic
Variable	Type Relax	Relax types (e.g., BINARY $\rightarrow$ CONTINUOUS)
	Bound Remove	Remove lower/upper bounds
Objective	Sense Flip	Swap direction (e.g., MIN $\rightarrow$ MAX)
	Coeff Noise	Flip sign of variable coefficient in objective
	Term Drop	Remove a term from objective expression
Constraint	Comparator Flip	Swap inequality signs (e.g., $\geq \rightarrow \leq$)
	RHS Shift	Modify constant C to $C \times (1 \pm \epsilon)$
	Var Swap	Swap positions of two variables of same type
	Index Mismatch	Swap iteration sets in loop constructs
	Constraint Drop	Remove an entire constraint declaration

语义奖励模型

- 模型训练：
 - 监督微调：训练集**规模小**，容易**过拟合**。
 - 基于二分类的对比学习：忽略了**语义错误程度**的区分，学习不够全面。
 - 使用**解距离**定义软标签，结合**Bradley-Terry模型**进行训练，训练样本扩大，且模型能学到更全面的解偏好。
- 模型推理：
 - 产出的原生奖励值为无界实数，通过**Sigmoid函数**将其归一化以作为语义一致性的衡量

解距离

$$\delta(C) = \frac{|\hat{y} - y^*|}{|y^*| + \epsilon}$$

Bradley-Terry损失函数


$$\mathcal{L}(\theta) = - \mathbb{E}_{(P_k, C_{win}, C_{lose}) \sim \mathcal{D}_{pref}} [\log \sigma (R(P_k, C_{win}) - R(P_k, C_{lose}))]$$

Sigmoid函数

$$Sig(x) = (1 + e^{-x})^{-1}$$

自适应修复系统

- 初始解筛选：
 - **采样初始解**并用语义奖励模型计算得分 S_{init} 。根据**阈值大小**判断是否进行后续推理过程。
- 层次化分解：
 - 将整个建模过程分为**建模策略**、**数学模型**、**求解器代码**三层。执行MCTS以探索假设空间。




自适应修复系统

选择 $UCT(v^{(i+1)}) = Q(v^{(i+1)}) + \omega \cdot \sqrt{\frac{\ln N(v^{(i)})}{N(v^{(i+1)}) + \epsilon'}}$

扩展 $v_j^{(i+1)} \sim \pi_\theta(\cdot | \tilde{v}, P), \quad j \in \{1, \dots, K\}.$

模拟 $S = R(P, C)$

反向传播 $Q(v) \leftarrow Q(v) + \frac{S - Q(v)}{N(v)}.$



Algorithm 1 Semantic-Guided MCTS Process

Input: Problem Description P , Semantic Reward Model R , Policy Network π_θ , Budget T_{max} , Expansion Count K , Exploration Constant ω

Output: Best Solver Code C^*


- 1: Initialize tree $\mathcal{T}$ with root node $v^{(0)}$
- 2: **for** $iter \leftarrow 1$ to T_{max} **do**
- 3: $v^{(i)} \leftarrow v^{(0)}$ ▷ Phase 1: Selection
- 4: **while** $v^{(i)}$ is not a leaf node **do**
- 5: $v^{(i+1)} \leftarrow \arg \max_{u \in \text{children}(v^{(i)})} \left(Q(u) + \omega \cdot \sqrt{\frac{\ln N(v^{(i)})}{N(u) + \epsilon}} \right)$
- 6: $\tilde{v} \leftarrow v^{(i+1)}$
- 7: **if** $\tilde{v}$ is not a terminal state **then** ▷ Phase 2: Expansion
- 8: Sample $\{v_1^{(i+1)}, \dots, v_K^{(i+1)}\}$ via $v_j^{(i+1)} \sim \pi_\theta(\cdot | \tilde{v}, P)$
- 9: Add $\{v_1^{(i+1)}, \dots, v_K^{(i+1)}\}$ to $\mathcal{T}$ as children of $\tilde{v}$
- 10: $v^* \leftarrow$ Select a node from $\{v_1^{(i+1)}, \dots, v_K^{(i+1)}\}$
- 11: **else**
- 12: $v^* \leftarrow \tilde{v}$
- 13: **if** v^* is not a terminal state **then** ▷ Phase 3: Evaluation
- 14: $C \leftarrow \text{ROLLOUT}(v^*, \pi_\theta)$
- 15: **else**
- 16: $C \leftarrow$ Extract solver code from v^*
- 17: Score $S \leftarrow R(P, C)$
- 18: $v \leftarrow v^*$ ▷ Phase 4: Backpropagation
- 19: **while** $v \neq \text{NULL}$ **do**
- 20: $N(v) \leftarrow N(v) + 1$
- 21: $Q(v) \leftarrow Q(v) + \frac{S - Q(v)}{N(v)}$
- 22: $v \leftarrow \text{Parent}(v)$
- 23: $v \leftarrow v^{(0)}$
- 24: **for** $k \leftarrow 1$ to 3 **do**
- 25: $v \leftarrow \arg \max_{u \in \text{children}(v)} Q(u)$
- 26: $C^* \leftarrow$ Solver code of v
- 27: **return** C^*

实验设计与结果

- 数据集选择:

- **标准数据集**: NL4Opt^[9](NO), NL4LP^[3](NL), EasyLP^[10](EL)和ReSocratic^[25](RS), 这些数据集主要由标准的**线性规划**问题组成。
- **工业数据集**: IndustryOR^[2](IO), ComplexLP^[10](CL)和ComplexOR^[6](CO)。这些数据集具有复杂的**隐式约束与长上下文表述**, 是测试SemOPT能否纠正**语义错误**的主要依据。

Dataset	Size	Complexity
NL4Opt	289	5.59
IndustryOR	100	14.06
EasyLP	652	7.12
ComplexLP	211	13.35
ReSocratic	605	7.45
NLP4LP	269	5.58
ComplexOR	37	5.98



实验设计与结果

- 测试基线：（1）**标准**：标准提示和自我反思^[27]；（2）**工作流**：OptiMUS^[3]，Chain-of-Experts^[6]和OptiTree^[18]；（3）**回译验证**：SAC-Opt^[4]；（4）**监督微调**：ORLM^[2]和SIRL^[26]；（5）**层次化搜索**：Autoformulator^[5]和SolverLLM^[8]。

类型	方法/设置	NO	IO	EL	CL	NL	RS	CO
标准	Prompting	65.4%	47.6%	87.2%	41.4%	75.8%	67.5%	44.4%
	Reflection	65.0%	54.8%	87.2%	39.6%	76.4%	68.0%	38.9%
工作流	OptiMUS	79.0%	57.1%	93.6%	45.1%	90.5%	78.7%	59.3%
	CoE	74.8%	59.5%	93.2%	46.0%	90.5%	79.4%	50.0%
	OptiTree	73.8%	47.6%	93.4%	73.8%	82.0%	72.5%	63.0%
回译验证	SAC-Opt	85.1%	57.1%	94.3%	74.8%	95.5%	89.3%	55.6%
监督微调	ORLM	73.8%	42.9%	90.4%	59.5%	76.4%	61.8%	50.0%
	SIRL	86.4%	45.2%	<u>98.1%</u>	80.2%	95.5%	87.8%	44.4%
层次化搜索	Autoformulator	76.2%	49.2%	94.9%	52.3%	85.4%	79.4%	48.1%
	SolverLLM	82.7%	50.8%	94.5%	68.5%	88.8%	83.1%	57.4%
本文	SemOPT(BoN)	<u>87.9%</u>	<u>64.3%</u>	97.6%	<u>82.9%</u>	<u>96.1%</u>	<u>89.8%</u>	<u>66.7%</u>
	SemOPT(P@N)	91.1%	66.7%	98.5%	86.5%	99.4%	93.1%	72.2%

SemOPT在绝大多数数据集上达到**SOTA**水平。

标准方法和工作流方法表现一般，因为其**缺乏严格的验证机制**。


微调方法在复杂问题上表现差，说明SFT难以学习出**深度推理能力**。

回译验证、层次化搜索效果不如SemOPT，说明我们**搜索设置的有效性**。

实验设计与结果

- 鲁棒性分析：SemOPT是否在**复杂问题**上是否能维持良好表现？
 - 根据数据集各问题的**难度标签**进行分类，测试各难度子集相比**最先进基线**的提升。
 - 选择NL4Opt这一标准数据集与ComplexLP, ComplexOR两个工业数据集作为代表数据集进行分析。


Dataset	Difficulty	SOTA Baseline	SemOPT
NL4Opt	Easy	93.6%	94.4% (↑0.8%)
	Medium	82.0%	84.0% (↑2.0%)
	Hard	69.2%	71.8% (↑2.6%)
ComplexLP	Easy	88.6%	88.6% (+0.0%)
	Medium	94.1%	97.1% (↑3.0%)
	Hard	54.5%	63.6% (↑9.1%)
ComplexOR	Easy	74.1%	77.8% (↑3.7%)
	Medium	50.0%	50.0% (+0.0%)
	Hard	52.3%	57.1% (↑4.8%)




SemOPT在困难子集上的提升最大，证明**语义引导搜索的不可或缺**。

实验设计与结果

- 组件**消融**实验：SemOPT的各个组件对于最终性能而言是否都是不可或缺的？
 - 三组消融变体：**评估器变体**，**门控变体**，**骨干模型变体**。
 - 实验一：更换**评估器**，实验证明语义奖励模型的效果**最好**。
 - 实验二：取消**门控机制**，实验证明SemOPT在保证正确率的同时极大**降低了推理成本**。



SemOPT在使用**语义奖励模型**时正确率最高，证明其**有效性与必要性**






SemOPT在使用门控机制时**大幅降低推理成本**，证明其**有效性与必要性**

实验设计与结果

- 消融实验三-骨干模型变体：更换LLM基座，实验证明对于各种LLM效果均有提升。
- 效率实验：与标准提示方法的Pass@N进行对比，实验证明效率、正确率均有提升。

Backbone LLM	Method [†]	NL4Opt	ComplexLP	ComplexOR
Gemini-2.5-Flash-Lite	Prompting (BoN)	70.1%	64.0%	55.6%
	SemOPT (BoN)	79.0% (↑8.9%)	75.7% (↑11.7%)	63.0% (↑7.4%)
GPT-4.1 mini	Prompting (BoN)	74.8%	64.8%	55.6%
	SemOPT (BoN)	86.9% (↑12.1%)	79.3% (↑14.5%)	66.7% (↑11.1%)
Qwen3-Max	Prompting (BoN)	76.2%	66.7%	55.6%
	SemOPT (BoN)	88.8% (↑12.6%)	82.0% (↑15.3%)	66.7% (↑11.1%)

SemOPT使用各种大小的LLM基座时效果均提升，证明其泛化性



SemOPT在较低的API成本下打破了标准提示的正确率瓶颈，证明其效率

存在的问题与后续工作

存在的问题

- 当前问题可总结如下：
 - SemOPT在EasyLP这一简单数据集上，Best-of-N设置正确率**低于SIRL**这一结合监督微调与强化学习的方法。
 - 各个数据集给出的**难度标签设置**不合理，SemOPT在中等难度子集上的提升可能低于简单子集，或高于复杂子集。
 - SemOPT应该使用**更加先进的LLM基座**以证明其泛化性。

类型	方法/设置	NO	IO	EL	CL	NL	RS	CO
标准	Prompting	65.4%	47.6%	87.2%	41.4%	75.8%	67.5%	44.4%
	Reflection	65.0%	54.8%	87.2%	39.6%	76.4%	68.0%	38.9%
workflows	OptiMUS	79.0%	57.1%	93.6%	45.1%	90.5%	78.7%	59.3%
	CoE	74.8%	59.5%	93.2%	46.0%	90.5%	79.4%	50.0%
	OptiTree	73.8%	47.6%	93.4%	73.8%	82.0%	72.5%	63.0%
回译验证	SAC-Opt	85.1%	57.1%	94.3%	74.8%	95.5%	89.3%	55.6%
监督微调	ORLM	73.8%	42.9%	90.4%	59.5%	76.4%	61.8%	50.0%
	SIRL	86.4%	45.2%	98.1%	80.2%	95.5%	87.8%	44.4%
层次化搜索	Autoformulator	76.2%	49.2%	94.9%	52.3%	85.4%	79.4%	48.1%
	SolverLLM	82.7%	50.8%	94.5%	68.5%	88.8%	83.1%	57.4%
本文	SemOPT(BoN)	87.9%	64.3%	97.6%	82.9%	96.1%	89.8%	66.7%
	SemOPT(P@N)	91.1%	66.7%	98.5%	86.5%	99.4%	93.1%	72.2%

Dataset	Difficulty	SOTA Baseline	SemOPT
NL4Opt	Easy	93.6%	94.4% (↑0.8%)
	Medium	82.0%	84.0% (↑2.0%)
	Hard	69.2%	71.8% (↑2.6%)
ComplexLP	Easy	88.6%	88.6% (+0.0%)
	Medium	94.1%	97.1% (↑3.0%)
	Hard	54.5%	63.6% (↑9.1%)
ComplexOR	Easy	74.1%	77.8% (↑3.7%)
	Medium	50.0%	50.0% (+0.0%)
	Hard	52.3%	57.1% (↑4.8%)

研究计划

个人任务计划	时间：2025 年 12 月 至 2026 年 6 月	
	周	主要任务目标
	1-2	确定毕设题目，调研项目背景及国内外相关研究
	3	开题答辩，设计实验并搜集数据，搭建实验环境
	4-5	训练语义奖励模型，搭建自适应修复系统框架
	6-7	进行初步实验并分析改进点，调整现有模型与框架
	8	撰写论文部分初稿
	9	准备中期答辩
	10-15	根据实验结果进一步完善方法，完成论文
	16	最终答辩

个人任务计划	时间：2025 年 4 月 至 2026 年 6 月	
	周	主要任务目标
	9-10	准备并完成中期答辩，根据意见对现有论文表述和内容进行修改。
	11-12	分析 SemOPT 在 EasyLP 等简单数据集上的错误模式，对框架进行微调，旨在提升其正确率
	13-14	完善实验并分析结果，撰写毕业论文
	15-16	完善论文并修改格式，准备最终答辩

参考文献

参考文献

- [1]徐翔斌,李志鹏.强化学习在运筹学的应用:研究进展与展望[J].运筹与管理,2020,29(05):227-239.
- [2]Huang C, Tang Z, Hu S, et al. ORLM: A Customizable Framework in Training Large Models for Automated Optimization Modeling[J]. Operations Research, 2025, 73(6): 2986–3009.
- [3]Ahmaditeshnizi A, Gao W, Udell M. OptiMUS: Scalable Optimization Modeling with (MI)LP Solvers and Large Language Models[C]//International Conference on Machine Learning. PMLR, 2024: 577–596.
- [4]Zhang Y, Kang Q, Chen Y, et al. Optimization Modeling via Semantic Anchored Alignment[J]. arXiv preprint arXiv:2510.05115, 2025.
- [5]Astorga N, Liu T, Xiao Y, et al. Autoformulation of Mathematical Optimization Models Using LLMs[C]//International Conference on Machine Learning, 2025.
- [6]Xiao Z, Zhang D, Wu Y, et al. Chain-of-Experts: When LLMs Meet Complex Operations Research Problems[C]//International Conference on Learning Representations, 2023.
- [7]Jiang C, Shu X, Qian H, et al. LLMOPT: Learning to Define and Solve General Optimization Problems from Scratch[C]//International Conference on Learning Representations, 2024.
- [8]Li D, Zhao X, Yu L, et al. SolverLLM: Leveraging Test-Time Scaling for Optimization Problem via LLM-Guided Search[C]//The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025.
- [9]Ramamonjison R, Yu T, Li R, et al. NL4Opt Competition: Formulating Optimization Problems Based on Their Natural Language Descriptions[C]//Proceedings of the NeurIPS 2022 Competitions Track. PMLR, 2023: 189–203.
- [10]Huang X, Shen Q, Hu Y, et al. LLMs for Mathematical Modeling: Towards Bridging the Gap between Natural and Mathematical Languages[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Association for Computational Linguistics, 2025: 2678–2710.
- [11]Dong G, Yuan H, Lu K, et al. How Abilities in Large Language Models Are Affected by Supervised Fine-tuning Data Composition[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2024: 177–198.

参考文献

- [12]Xiao Z, Xie J, Xu L, et al. A Survey of Optimization Modeling Meets LLMs: Progress and Future Directions[C]//Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2025: 10742-10750.
- [13]Lu J, Wan Y, Huang Y, et al. FormalAlign: Automated Alignment Evaluation for Autoformalization[C]//The Thirteenth International Conference on Learning Representations, 2024.
- [14]刘起东,何文轩,姚恩广,等.X-反馈强化学习: 前沿进展与展望[J/OL].计算机学报,1-25[2026-03-11].<https://link.cnki.net/urlid/11.1826.TP.20251117.1734.035>.
- [15]Sun H, Shen Y, Ton J F. Rethinking Reward Modeling in Preference-based Large Language Model Alignment[C]//The Thirteenth International Conference on Learning Representations, 2024.
- [16]Yang A Z H, Le Goues C, Martins R, et al. Large Language Models for Test-Free Fault Localization[C]//Proceedings of the IEEE/ACM 46th International Conference on Software Engineering. Association for Computing Machinery, 2024: 1-12.
- [17]Xie W, Hu Y X, Xu J, et al. MURKA: Multi-Reward Reinforcement Learning with Knowledge Alignment for Optimization Tasks[C]//The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025.
- [18]Liu H, Wang J, Cai Y, et al. OptiTree: Hierarchical Thoughts Generation with Tree Search for LLM Optimization Modeling[C]//The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025.
- [19]Michailidis K, Tsouros D, Guns T. Constraint Modelling with LLMs Using In-Context Learning[C]//30th International Conference on Principles and Practice of Constraint Programming. Schloss Dagstuhl - Leibniz-Zentrum für Informatik, 2024: 20:1–20:27.
- [20]Sun H, Shen Y, Ton J F. Rethinking Reward Modeling in Preference-based Large Language Model Alignment[C]//The Thirteenth International Conference on Learning Representations. 2024.
- [21]Ji Y, Li J, Xiang Y, et al. A Survey of Test-Time Compute: From Intuitive Inference to Deliberate Reasoning[J]. arXiv preprint arXiv:2501.02497, 2025.

参考文献

- [22]Misaki K, Inoue Y, Imajuku Y, et al. Wider or Deeper? Scaling LLM Inference-Time Compute with Adaptive Branching Tree Search[C]//ICLR 2025 Workshop on Foundation Models in the Wild. 2025.
- [23]Zhang J, Wang X, Mo F, et al. Entropy-Based Exploration Conduction for Multi-step Reasoning[J]. arXiv preprint arXiv:2503.15848, 2025.
- [24]Ding Y, Jiang W, Liu S, et al. Dynamic Parallel Tree Search for Efficient LLM Reasoning[J]. arXiv preprint arXiv:2502.16235, 2025.
- [25]Yang Z, Wang Y, Huang Y, et al. OptiBench Meets ReSocratic: Measure and Improve LLMs for Optimization Modeling[C]//The Thirteenth International Conference on Learning Representations. 2024.
- [26]Chen Y, Xia J, Shao S, et al. Solver-Informed RL: Grounding Large Language Models for Authentic Optimization Modeling[J]. arXiv preprint arXiv:2505.11792, 2025.
- [27]Shinn N, Cassano F, Gopinath A, et al. Reflexion: language agents with verbal reinforcement learning[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc., 2023: 8634–8652.

感谢各位老师
敬请批评指正

